看圖模型
真的看懂了嗎？

HallusionBench（CVPR 2024）
論文四大重點與 InternVL3-2B 單模型復現

用一張 RTX 3070 Ti 8GB，完成 1,129 題評估。

2026-10-21 · Stage 3 發布版

單題接受率 All	整組全對 qAcc	同圖全對 fAcc
54.65%	22.42%	28.90%

怎麼讀這份報告？

第一部分依四個重點說明原論文：摘要、目的、方法與成果。第二部分整理本次實作、八張分析圖、案例及可信度。文獻數字標為 Published Results；只有 InternVL3-2B 是本次實測。

All 包含 63 題官方 VS 無圖接受特例；診斷分類不等於模型內部成因。沒有獨立人工判分驗證。

此版不含第三方原始圖片。原本地含圖報告已核對為 20 頁；本版另行排版，頁數與該封存不同。完整原始回答、判分及來源版本請見專案資料。

GitHub：ChenBill900703 / HallusionBench-InternVL3-2B-Reproduction

HallusionBench 論文四大重點

本文件整理 Guan 等人在 CVPR 2024 發表的 HallusionBench。前三節解釋原論文，第四節先講作者成果，再清楚分開本次 InternVL3-2B 實驗。目的不是逐句翻譯，而是讓讀者能自己說明「為什麼要這樣測、數字又代表什麼」。

一、論文摘要

模型會說明圖片，不代表每次都真正看懂

大型視覺語言模型把影像處理與語言生成放在同一系統裡。使用者可以給它一張圖，要求它描述物件、讀表格、比較大小或推理事件順序。這讓模型看起來能「理解圖片」，但流暢的解釋也可能掩蓋錯誤。

模型有兩種可用資訊：訓練時學到的知識，以及眼前的圖片。兩者一致時，很難分辨模型究竟靠哪一個作答。假設模型知道某品牌標誌常搭配特定文字，即使當前圖已換字，它仍可能說出原品牌。

另一種問題是圖片本身被誤讀。兩個相同大小的圓，放在不同大小的周圍圓中，可能看起來一大一小；圖表線條與圖例的對應、角度和反轉影格也可能被看錯。回答一樣是錯的，背後需要改善的能力卻可能不同。

兩個研究用語

Language Hallucination（語言幻覺） 在本文指向模型未適當依視覺內容更新、而沿用語言或知識先驗的情況。例如無圖時回答某國人口最多，看到修改圖後仍沿用相同答案。

Visual Illusion（視覺誤判） 在本文較廣泛地包含視覺輸入被錯誤解釋的情況，不限於人類熟悉的錯覺圖。例如把圖例顏色看錯、把修改文字仍讀成原字，或把穿衣與脫衣順序混淆。

這兩類可能同時出現。模型先讀錯字，又用熟悉品牌解釋它，單靠一句回答很難拆開。HallusionBench 因此利用控制配對，提供一致的診斷方法；分類是可操作的研究規則，不是直接觀察模型的內部原因。

資料與主要貢獻

資料共有 346 張影像、1,129 個問答項目，影像包括 165 張原圖及 181 張人工修改圖。作者把相關問答整理成 455 個控制組，並檢查同圖回答的一致性。

主要貢獻有三項：第一，設計會讓知識與當前圖像衝突的對照題；第二，同時觀察單題、整組、整圖的正確性，而不是只看一個平均；第三，把回答傾向、一致性與失誤類型放進同一評估流程，供後續研究定位問題。

二、本篇論文目的

1. 補足一般 VQA 成績看不到的問題

傳統看圖問答常把每題獨立計分。模型即使靠資料集常見答案、語言線索或常識猜中，也可能拿到分數。這不代表它能處理「圖片故意改得和常識不同」的情況。

白話例子：原本圖上是一個熟悉品牌，模型說對品牌名稱；把標誌下方文字改掉後，它還是說同一品牌。如果只測第一張圖，就會漏掉這種失誤。

2. 檢查「同一問題換條件」是否仍然可靠

一題答對可能只是剛好猜對。若相關條件都對，才更有理由相信它會根據條件改變判斷。

例子：地鐵藍線原本經過某站，修改圖把藍紅互換。模型應在原圖與修改圖給出不同答案。這就是 qAcc 要求整個控制組都正確的原因。

3. 用無圖條件看模型原本知道什麼

VS 題目可以先不給圖，觀察模型的知識或棄答；再加入原圖與修改圖，看它是否更新答案。VD 則必須依圖回答，無法只靠一般常識處理。

例子：問真實世界某年人口最多的國家，模型可能有記憶；但修改過的圖表可能故意把數值換給另一國。研究重點是它是否依「這張圖」回答，而非永遠回答真實世界的常見答案。

4. 檢查同一張圖面對不同問題是否互相矛盾

正確理解應能支持不同、但邏輯相關的問法。只要問法改變就自相矛盾，模型的理解就不穩定。

例子：同一張圖先說「兩條線一樣長」，再說「上面比下面長」。即使其中一題碰巧正確，也不能當成整張圖都理解正確。fAcc 因此要求同圖的相關問題全部通過。

5. 讓後續改善更有方向

若失誤主要與 OCR、圖例或影格順序有關，可研究更精確的視覺證據；若修改後仍沿用原答案，可研究如何避免知識先驗蓋過當前圖像。

但這仍是研究假說。控制配對能揭露輸出行為，無法單獨證明注意力、記憶或視覺編碼器哪一層真正造成失誤。

三、研究方法

第一步：建立原圖與人工修改圖

修改可能是換文字、替換物件、改變圖表標示、調整幾何或反轉影格順序。重點是建立可檢查的條件差異，讓研究者知道答案是否應隨圖改變。

同一張圖可以搭配多個問法，因此 346 張圖對應到 1,129 個問答項目。圖片張數、題數與控制組數是三個不同數量。

第二步：分成 VD 與 VS

類型	需要什麼資訊？	容易理解的例子
VD：Visual Dependent	必須看圖才知道本題答案	圖中圓是否同大、角度、影格先後
VS：Visual Supplement	常識可能先給出答案，圖片再補充或修改	人口圖、地鐵圖、名人演說、表格

VD 類別有 Illusion、Math、Video、Poster、Figure；VS 有 Chart、Table、Map、OCR。Poster 在官方欄位中是 VD/ocr，不能和 VS/ocr 混為同一類。

第三步：保留完整回答並判定語意

官方 teacher prompt 給 Judge 題目、文字參考與模型回答。評估關心的是整段回答是否與參考衝突，不是只截取第一個 Yes 或 No。

例如回答「No，資料不足，無法確認」，完整意思是棄答，不能直接當成明確否定。又例如模型先說 No，後面卻說出同命題的肯定結論，就需要保留矛盾。

原文以 GPT-4 輔助判分，對評估重複取平均，並有人類評分對照。本次換成 GPT-6.1，因此必須把 Judge 差異當成限制。

第四步：套用官方 correctness 規則

原始語意標籤 0、1、2，分別是錯誤、正確、不確定。最後計算接受與否時，VS 無圖條件有例外：1 或 2 都被接受；其他條件只接受 1。

原因是無圖時誠實說不知道可以合理，但程式實際接受所有 2，包括部分內部矛盾。報告必須同時保存原始標籤與最終接受值，避免把棄答說成模型真的知道。

第五步：計算五項主指標

指標	怎麼計算？	哪種失誤會被看見？
All / aAcc	最終被接受題數除以全部題數	整體單題成功比例
qAcc	整組全對的控制組除以全部控制組	原圖對、修改圖錯
fAcc	全題都對的實體圖除以全部實體圖	同圖不同問法不穩定
Easy	先篩非修改條件，再以控制組全對計算	非修改條件的整組表現
Hard	先篩修改條件，再以控制組全對計算	修改條件與多修改變體的整組表現

一組三題只有兩題對，All 會有兩個成功，但 qAcc 為零。Easy / Hard 在此實作是控制組指標，不能當成一般單題平均；同一組有多張修改圖時，Hard 仍要全部正確。

第六步：檢查偏向、一致性與診斷

Yes Percentage Difference觀察預測的肯定傾向與 GT 的肯定比例差。**FP Ratio**在官方實作中是所有錯誤裡 GT=0 的比例，不是傳統分類器的 FP/(FP+TN)。官方程式從 correctness 與 GT 反推極性，遇到棄答或參考衝突時可能不等於實際立場，所以本次另外直接統計完整回答的 yes/no。

Consistency Test把一張圖分成全部對、部分對、全部錯。它是圖層級指標，與兩段回答的 same/different 比較不同。

診斷流程以 baseline 和當前回答的正確性，再搭配兩段回答是否互相衝突，分成 LH、VI、Mixed。VD baseline 是原圖，VS baseline 是無圖。例如 VS 無圖正確，修改圖錯且仍沿用同一答案，會進入語言幻覺相關分支。

本次保存 same/different/uncertain；uncertain 不是已確認 different。送入官方二元欄時主版本將它投影為 0，另外計算投影為 1 的敏感度。

另有必須揭露的版本差異：VD baseline 正確、修改回答錯且 same 時，論文 Figure 3 指向 LH，官方程式設為 Mixed。本次主表採程式版本，替代分支另列，不能混用後挑好看的比例。

四、呈現的成果

原作者的結果：Published Results

原文評估 15 種模型。Table 2 的 GPT-4V 人工評分 qAcc=31.42%、fAcc=44.22%、All=67.58%；同模型 GPT4-Assisted 分別為 28.79%、39.88%、65.28%。這也說明評分方式會影響結果。

Table 3 顯示各模型都有不同的回答偏向與失誤分布。Figure 4 的子類別分析指出 Math、Illusion、Video 等挑戰；Figure 5 用幾何、錯覺及反序影格展示模型可能忽略關鍵資訊。這些案例讓研究者看到「答案看似合理，卻沒有跟著視覺條件更新」的問題。

原文 Table 2 · Published Results	qAcc	fAcc	All
GPT-4V · Human	31.42%	44.22%	67.58%
GPT-4V · GPT4-Assisted	28.79%	39.88%	65.28%
LLaVA-1.5 · GPT4-Assisted	10.55%	24.86%	46.94%
Claude 3 · GPT4-Assisted	21.76%	28.61%	56.86%
Qwen-VL · GPT4-Assisted	5.93%	6.65%	39.15%

摘要說其他模型低於 16%，但 Table 2 的 Claude 3 為 21.76%；本文件明列正式表格結果，避免把摘要的一句概括延伸成不正確結論。

本次復現的結果：Our Measured Results

唯一實測 InternVL3-2B，在 RTX 3070 Ti 8GB 完成全部 1,129 題。本次不是訓練新模型，也沒有重跑 GPT-4V、LLaVA、Claude 或 Qwen-VL。

指標	正確 / 分母	成績
qAcc	102 / 455 控制組	22.42%
fAcc	100 / 346 張圖	28.90%
Easy	251 / 455 控制組	55.16%
Hard	193 / 430 控制組	44.88%
All	617 / 1,129 題	54.65%

原始語意為正確 554、錯誤 412、不確定 163。最終 617 個接受包括 63 個 VS 無圖例外。因此可以說「依官方規則接受 54.65%」，不能說「54.65% 題目都明確知道」。

同圖一致性為全對 100 / 346=28.90%、部分對 177 / 346=51.16%、全錯 69 / 346=19.94%。512 個錯誤依官方規則分成 LH 112=21.88%、VI 279=54.49%、Mixed 121=23.63%。原圖逐題 59.96%，修改圖 46.83%；Math 34.26%、Video 44.12%、Map 39.58%。

這些數字共同顯示：單題成功不代表跨條件穩定。修改圖、幾何與時序值得進一步研究；但題目組成不同、Judge 不是原文版本，也只有一個模型，不能直接作一般能力排名或內部機制推論。

可信度與限制

原始回答、官方 GT 與最終標籤都可追溯，計算可在無 GPU、無付費 API 下重做。v2 已全量重審，但仍由同一對話模型執行，沒有獨立人類驗證。32 題參考疑義、87 筆解釋問題、40 題達輸出上限與 18 題開放式問題均保留。

改善方向是先讓模型指出支持結論的圖像證據，例如 OCR、圖例或影格順序，再檢查推論是否合理。本次沒有把這個建議冒充已實作的改善方法。

來源：CVPR 正式論文、官方程式、本次完整結果。

本次復現完整整理

1. 實驗範圍：只做一個真正能跑完的模型

本次使用 OpenGVLab/InternVL3-2B，在單張 RTX 3070 Ti 8GB 完成 HallusionBench 的 1,129 題。研究內容是評估既有模型，不是訓練新模型，也不是重新執行原作者的 15 個模型。

有些下載紀錄提到曾考慮的 Qwen 模型，那是前期候選下載，不是正式推論結果。正式成績的原始回答全部來自 InternVL3-2B；25 題 smoke test 另放，沒有混入 1,129 題分母。

2. 環境與設定

項目	設定
GPU / CPU	RTX 3070 Ti 8GB / Intel Core i7-11700K
記憶體 / 系統	約 32GB / Windows 11
Python	3.12.14
PyTorch / Transformers	2.7.1+cu128 / 4.57.1
模型	OpenGVLab/InternVL3-2B
固定版本	899155015275a9b7338c7f4677e19c784e0e5a21
精度	BF16，無量化、無 CPU offload
一次處理	batch size 1
解碼	greedy、seed 42、max_new_tokens 128
圖像輸入	官方 448 像素動態切塊，最多 12 塊加縮圖

回答生成時間合計 50.64 分鐘。這不含安裝、下載、模型載入及中斷間隔，所以不能把它當整個研究專案的總耗時。

前 204 題的配置器 reserved cache 曾記錄 9.576 GiB；tensor allocated 峰值為 5.471 GiB。之後保留 checkpoint，限制每程序配置比例 90% 並逐題清理閒置快取。生成設定未改。NVIDIA 以 20 秒間隔取樣的實體顯存最高 7,987 MiB，不能保證捕捉所有瞬間峰值。這些不同的記憶體數字應分開解讀。

3. 真正執行過的流程

Stage 1：取得資料並產生回答。固定官方題目、模型與圖片鏡像版本；核對 1,129 題、455 控制組與 346 圖；只把問題與圖片交給推論程式，GT 另外保存。推論逐題保存回答、token、圖塊數、參數、耗時、錯誤與 GPU 紀錄。程式支援中斷續跑，失敗與重試保留在 attempts。

Stage 2：判分、計算與重審。GPT-6.1 Judge 閱讀完整回答，不只取開頭 Yes/No。保存原始語意與立場，再套用官方 correctness 特例。47 批初判、397 題歷史複核、仲裁及 v2 全量 1,129 題 / 674 配對稽核全部保留。

Stage 3：整理、驗收與發布。核對兩份 ZIP 與本地成果，撰寫繁體中文文件與可散布的無第三方原圖 PDF，檢查連結、檔案追蹤、隱私及遠端內容。此階段不改原始回答、GT 或最終判分，也不重新執行 GPU。

4. 評分規則：先看回答，再套官方例外

原始語意為 1=不衝突文字參考、0=核心承諾或明確事實與參考衝突、2=模型回答本身不確定或矛盾。v2 以官方 gt_answer_details 為優先；二元 gt_answer 不變，衝突另標 reference_dispute。

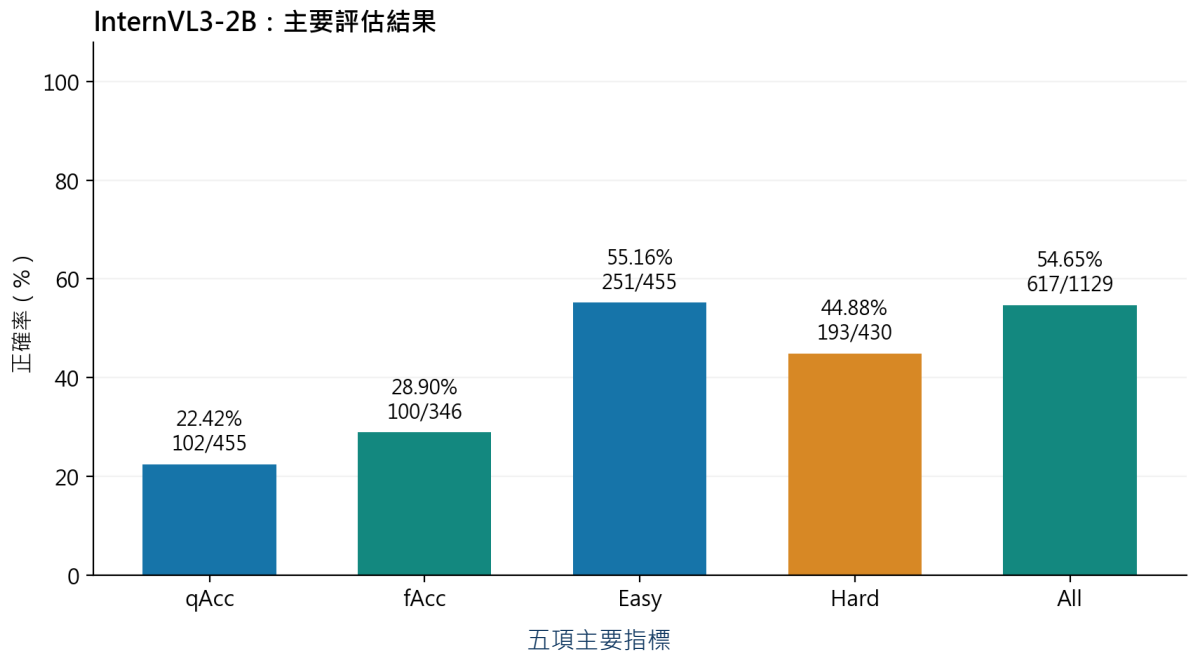
主分數和解釋品質分開。例如參考只給 BOC=145，模型也答 145，但半角推導錯誤，主語意仍可為 1，另標說明問題。若參考明說一隻鴨，模型卻把多隻小雞都稱幼鴨，這是明確數量衝突，主語意為 0。

VS 無圖條件按官方程式接受語意 1 或 2。其他條件只接受 1。本次 554 個語意正確加上 63 個無圖特例，得到最終 617 個接受。這是分數增加的明確來源，不是額外發現模型知道了 63 題。

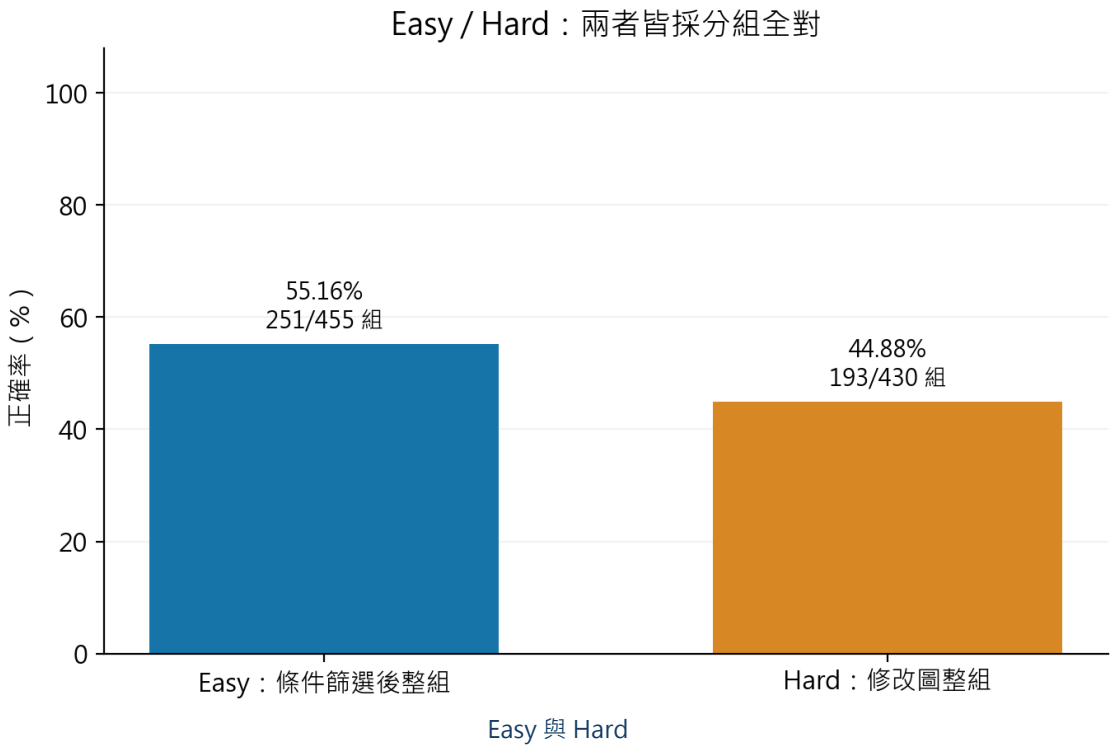
5. 結果與解釋

單題、控制組與整圖

指標	分子 / 分母	結果
qAcc	102 / 455 組	22.42%
fAcc	100 / 346 圖	28.90%
Easy	251 / 455 組	55.16%
Hard	193 / 430 組	44.88%
All	617 / 1,129 題	54.65%



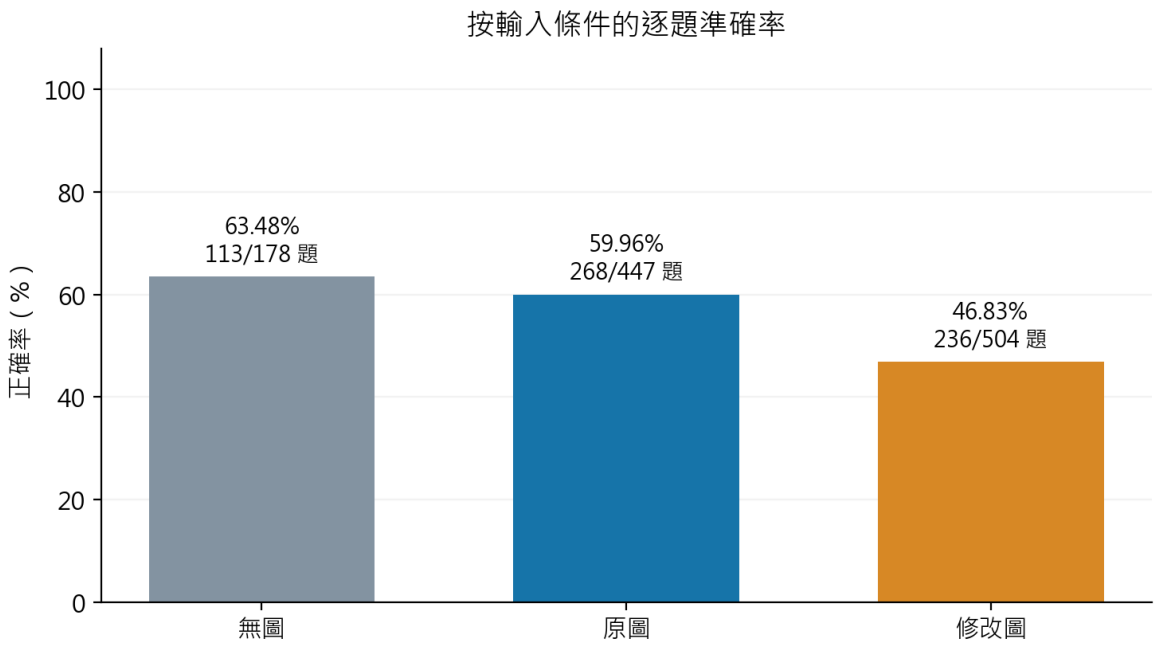
一組三題中兩題對，All 會計入兩次成功，但 qAcc 不會算這組通過。All 高於 qAcc 的主要意義，就是模型在相關條件下不夠穩定。Easy 與 Hard 都先按條件篩選，再算控制組全對；它們不是分別對 625 與 504 題直接取平均。



原圖與修改圖

原圖 268 / 447=59.96%，修改圖 236 / 504=46.83%。直接差距為 -13.13 個百分點，但題目組成不同。

另外在同時具有原圖與修改圖的 422 個控制組，先平均各組修改變體，再等權比較：原圖 59.48%、修改圖 48.10%，差 -11.37 點。以 seed=20261021 按組重抽 2,000 次，描述性的 95% 百分位區間為 [-18.13,-4.26] 點。這仍不是跨資料集保證或嚴格因果估計。

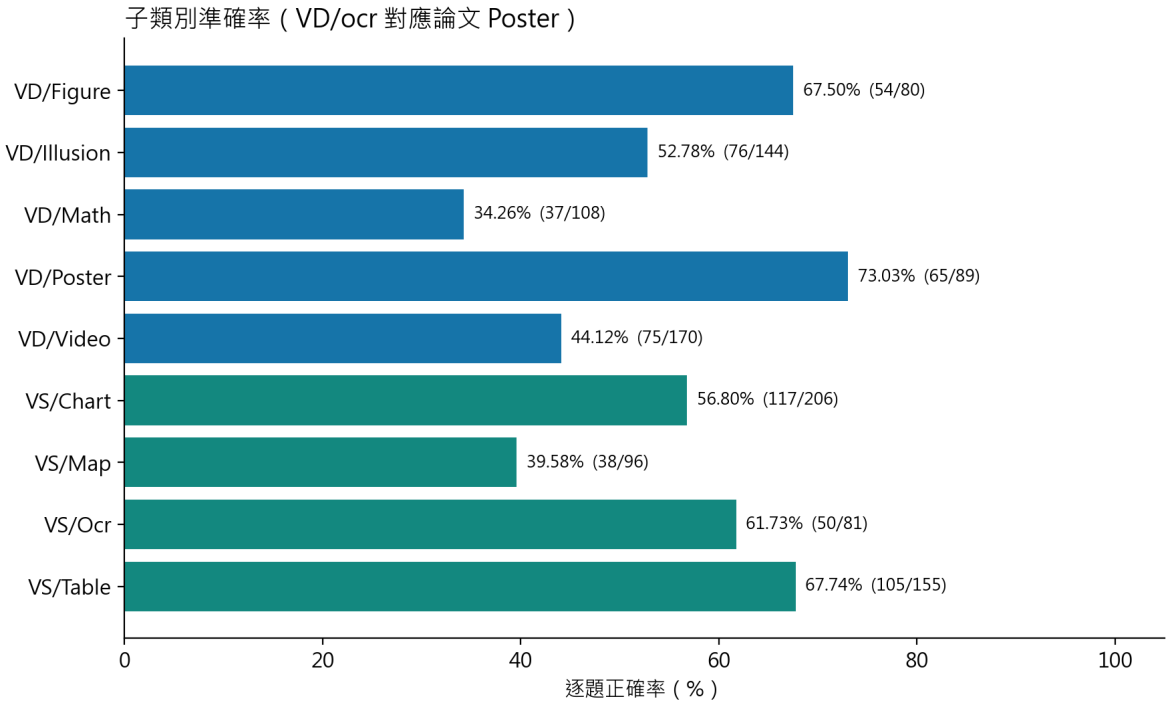


無圖含 VS 不確定接受規則；三條件題目組成不同。

依輸入條件比較

哪些題型較弱？

Math 37 / 108=34.26%、Video 75 / 170=44.12%、Map 38 / 96=39.58%。幾何關係、先後順序、圖例及空間關係都可能造成困難。這些是根據題型與輸出的合理解釋，沒有直接觀測內部機制。



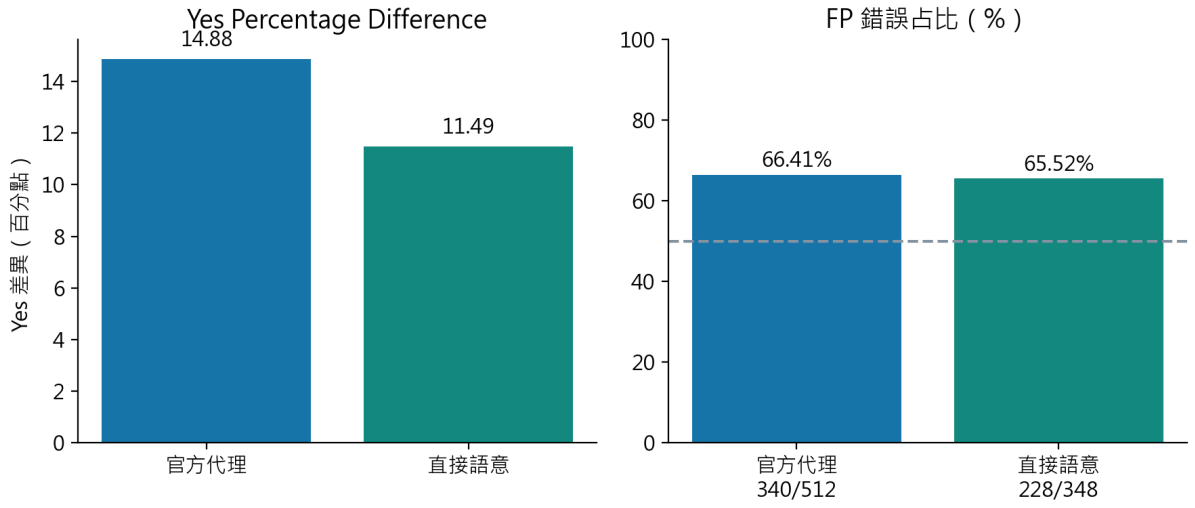
九種子類別

Yes/No 偏向

官方代理 PctDiff=(652-484) / 1129=0.1488；FP Ratio=340 / 512=0.6641。官方先由 correctness 與 GT 反推 Yes，不直接讀模型實際立場。

直接立場分析排除 18 題開放式題。在 1,111 個二元題中，yes 507、no 433、uncertain 104、ambiguous 67。940 個明確回答裡，Yes 53.94%，同子集 GT Yes 42.45%，差 11.49 個百分點。錯極性中的 FP 占比為 228 / 348=65.52%；傳統條件式 FPR 為 228 / 541=42.14%。

兩種版本都顯示 Yes 偏向，但不能把不同分母的數字互換。

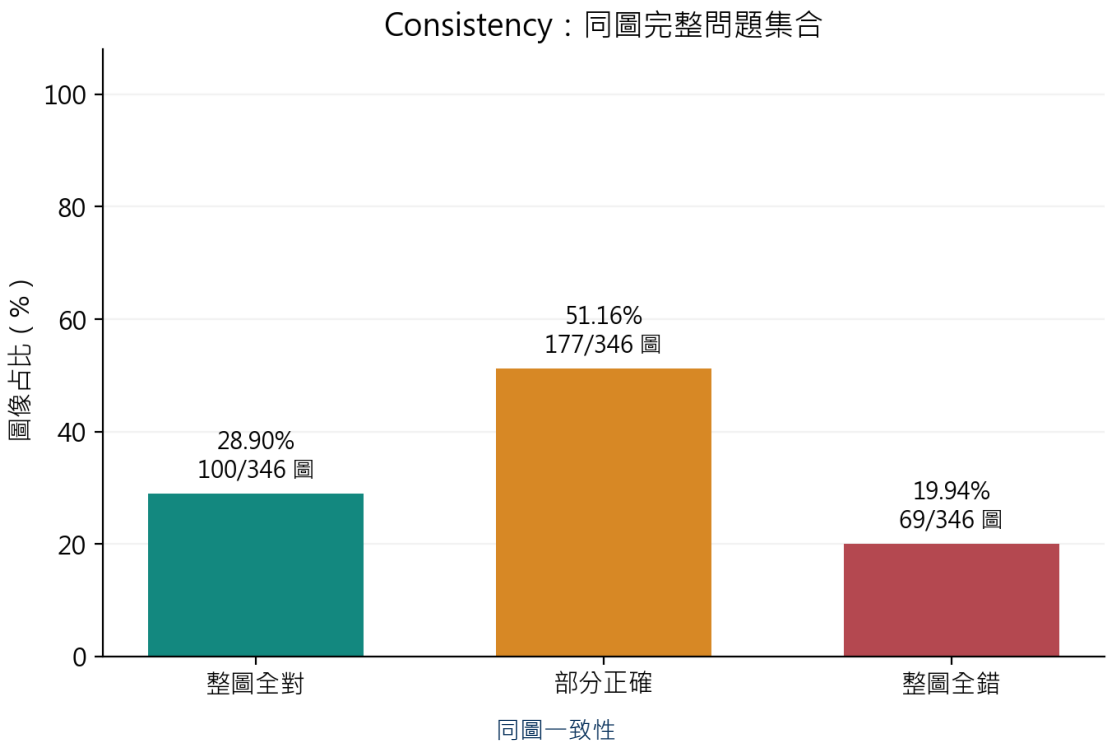


官方：全 1129 題；直接：940 筆明確二元回答。分母與定義不同。

官方代理與直接立場

一致性

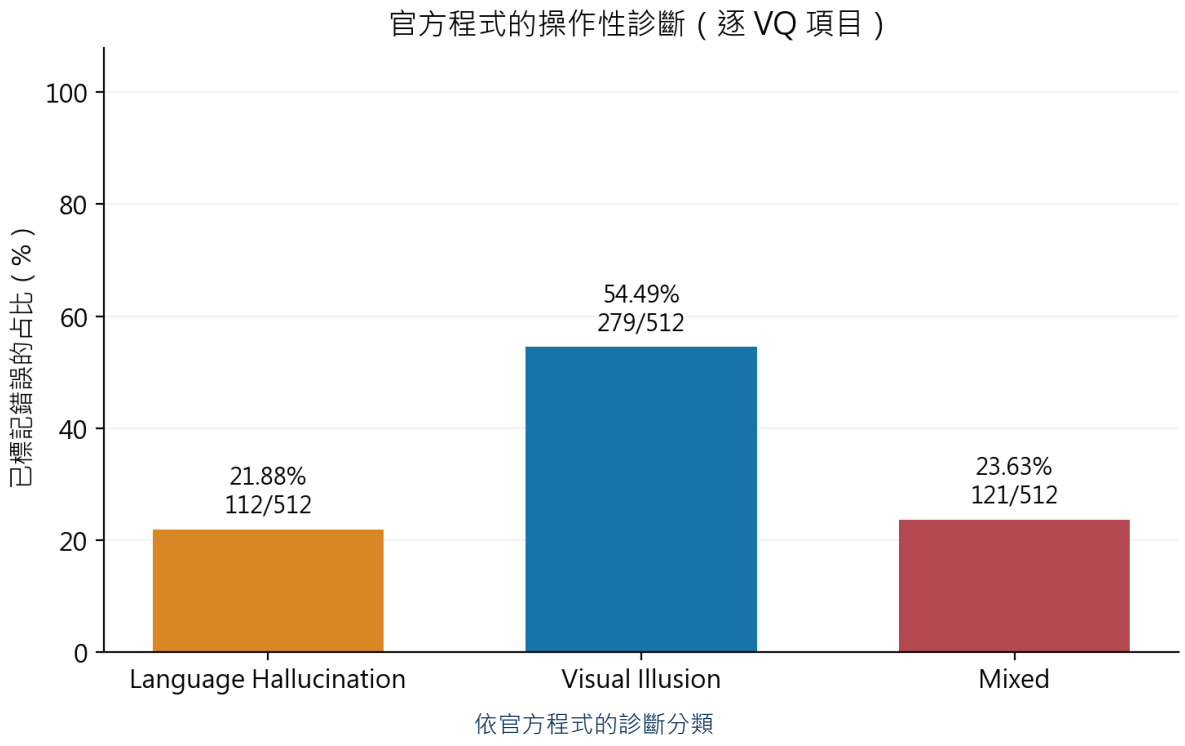
346 張圖中，全對 100=28.90%、部分對 177=51.16%、全錯 69=19.94%。同圖部分對的比例最高，表示模型理解會受問法影響。官方平均圖內逐題比例 figure score=0.54456，與整圖全對率 fAcc 不同。



錯誤診斷

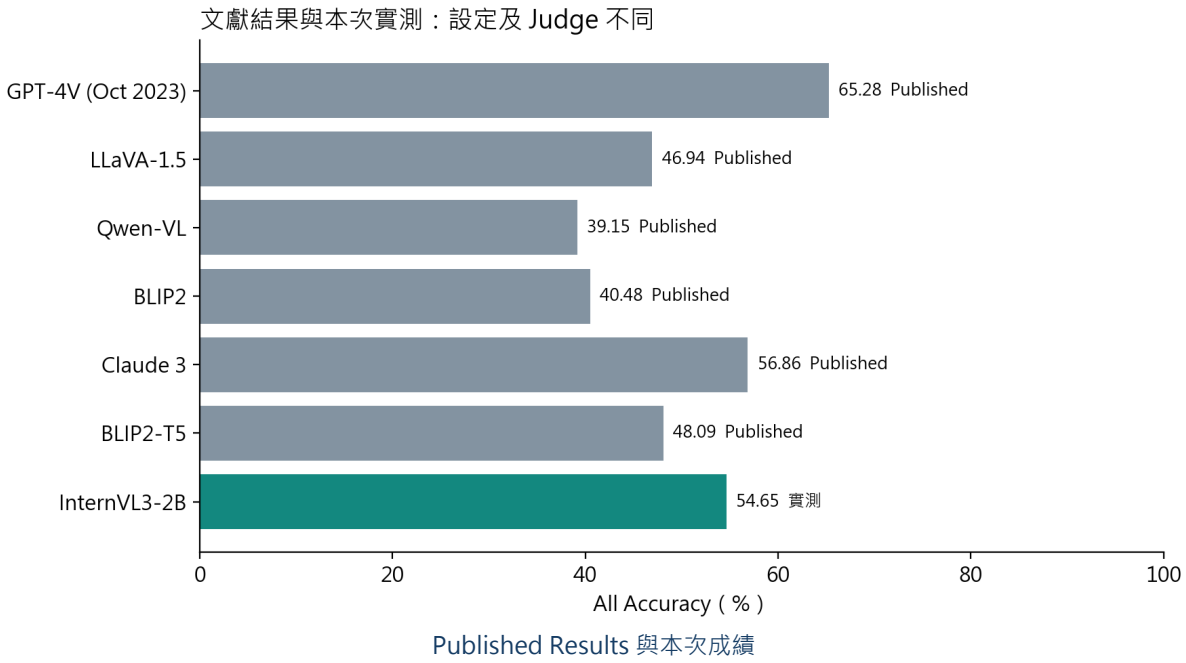
512 個錯誤分為 LH 112=21.88%、VI 279=54.49%、Mixed 121=23.63%。674 個配對關係為 same 287、different 232、uncertain 155。

主表將 uncertain 投影為 0。全部投影為 1 時，分類變為 LH 113、VI 278、Mixed 121，準確率不變。只把 Figure 3 的 VD 同答案錯誤分支改成圖示版本，會得到 LH 191、VI 279、Mixed 42；相較主版本有 79 個從 Mixed 移到 LH。這說明分支版本會明顯影響「哪種幻覺最多」的敘述。



VI 占比最高，只能說最多錯誤落入該控制規則分支；它可能同時包含辨識、推理、題意及拒答等因素。

6. 與原文模型並列，但不當成公平排名



Published Results 與本次成績

本次 All 高於部分歷史模型的發表值，但模型年代、輸入設定、圖片來源及 Judge 都不同，無法因此聲稱 InternVL3-2B 一般能力優於它們。此圖的用意是提供文獻背景，而非建立新的受控排行榜。

7. 六組案例告訴我們什麼？

修改地鐵圖仍回答原藍線可到、Red Deer 被解釋成 Red Bull、圓大小被誤判、反轉穿衣影格仍說穿衣、利率圖先 No 後正文肯定，以及 No 起頭但實際棄答，分別顯示更新答案、OCR 映射、感知、時序、矛盾與棄答處理的重要性。

每組案例都有真實 Sample ID、原文及判定，見資料說明。第三方圖像未放進發布版；來源、相對路徑及 SHA-256 仍保留。

8. 可信度與限制

項目	已完成的處理	尚不能宣稱什麼
原始資料	1,129 題 ID、原文、GT 與封存雜湊核對	鏡像與失效原圖包逐位元相同
語意 Judge	v2 全量重審，保留歷史標籤與理由	獨立人工驗證或黃金標註
參考疑義	32 題另列，保留分母及上下界	其他題一定沒有問題
說明問題	87 筆旗標，20 筆主分仍接受	全部贅述事實已外查
輸出截斷	40 題標記及複核	長度限制完全無害
開放式題	18 題區分 question_type	全部題目都是一般 Yes/No
診斷	官方分支與替代敏感度分列	直接證明模型內部成因

32 題疑義全設錯 / 全設對時，All 為 604-636 / 1129=53.50%-56.33%。這是指定集合的極端範圍，並非整體標註誤差的信賴區間。

歷史 397 題的語意重讀一致率 97.48%，只表示同模型兩次常給相同標籤，不能當準確率。v2 舊標籤可見，仍可能受錨定影響；沒有獨立人類或其他 Judge 的對照。

9. 可重現到什麼程度？

不用 GPU 就能重算已保存標籤的全部成績與圖表。這是決定性的資料處理：相同輸入標籤應得到相同分數。

重新推論則需要自行下載固定模型與圖片，並另用新 run_name；新機器、程式庫或硬體可能使輸出不同。重新請 GPT-6.1 主觀評分也可能不同，所以本專案保存實際使用過的判定，不把不同對話的再判定稱為保證一致。

主要入口：README 重現步驟；版本差異：完整方法紀錄；數值：overall.json。

從一個回答追到最後分數

先認識 Sample ID

例如 VS/map/6/2/0，表示 VS、Map 子類別、第 6 組、figure_id=2、第 0 問。完整 ID 是跨階段核對的鍵，不靠列號猜測。

問題控制組依 category、subcategory、set_id、question_id 組成。VD 的 figure_id=0 是原圖 baseline；VS 的 figure_id=0 是無圖 baseline。不能把所有 figure_id=0 都說成沒有圖片。

每一層保存什麼？

檔案	最重要的欄位	用途
results/internvl3_2b_bf16_tiles12/full/responses.jsonl	sample_id、model_response_raw、generation_details、inference_parameters	未改寫的原始回答與推論設定
data/manifests/ground_truth.jsonl	sample_id、official_row	官方題目與 GT
stage2/results/judgments.jsonl	semantic_correctness、predicted_stance、final_binary_correctness	最終判分，連同完整原文
stage2/results/pair_relations.jsonl	baseline_sample_id、sample_id、relation、reason	回答間的事實是否衝突
stage2/results/official_scored_rows.jsonl	judge_raw、same、correct	送入官方函數的資料
stage2/results/diagnostic_trace.jsonl	baseline_semantic、current_semantic、same_projected、diagnostic	每題為什麼分到 LH / VI / Mixed
stage2/results/control_group_scores.jsonl	sample_ids、correct_items、all_correct	qAcc 逐組的成員與結果
stage2/results/figure_group_scores.jsonl	sample_ids、all_correct	fAcc 逐圖結果
stage2/metrics/overall.json	numerator、denominator、percent	最終數字與公式

原始語意 0/1/2 和最終 correct=0/1 是不同欄位。只看 correct，會漏掉 VS 無圖例外接受的不確定回答。

實例：修改地鐵圖仍沿用原答案

查 VS/map/6/2/0。問題問依這張圖，能不能搭藍線前往 Pentagon。模型原文：

Yes. The Blue Line is one of the lines shown on the map, and it runs towards the Pentagon.

文字參考否定這個答案，所以 semantic_correctness=0，這題又是有圖條件，final_binary_correctness=0。其無圖 baseline VS/map/6/0/0 本來答對，修改題仍維持相同路線主張，relation=same，官方流程因此把修改題分到 LH。

這表示輸出沒有依修改路線更新，支持語言先驗影響的假說；它仍不能單獨證明模型內部只靠記憶。

六組案例

完整回答、標籤及圖像 metadata 見 case_studies.json。下列英文都是保存的真實模型輸出節錄；省略不代表原文不存在。

案例	真實 Sample ID	回答 / 判定與意義
A：地鐵修改	VS/map/6/0/0、6/1/0、6/2/0	三條件都說藍線可到；修改題錯且 same，官方歸 LH
B：Red Bull / Red Deer	VD/ocr/13/0/0、13/1/0	修改回答寫「The logo ... is for Red Bull, as indicated by the text Red Deer」；讀到新字卻映射錯，語意 0，完整文字與 baseline 不同，歸 VI
C：橙色圓	VD/illusion/0/0/0、0/1/0	原答 No 且說右圓較小，修改答 No 卻說較大；不能只因都 No 判 same
D：反轉穿衣順序	VD/video/5/0/0、5/1/0	兩者都說 baby attempting to put on the clothes；修改題錯且 same，官方程式歸 Mixed，Figure 3 替代分支則為 LH
E：利率圖	VS/chart/7/0/0、7/1/0、7/2/0	原圖先 No，正文卻說 US rates were higher，保留 ambiguous/2；修改圖文字結論對但數值比較有錯，另標說明問題
F：No 實際棄答	VS/chart/0/0/0	原文 No, the information provided is insufficient...；是 uncertain/2，依 VS 無圖例外被接受

表內縮寫後續 ID 只為節省版面，完整 ID 皆保存在 JSON 中。圖片來源版本為 lmms-lab-encoder/HallusionBench 的 cd417161857aefb23d878d42cf1bb53aa9dd646f；各圖路徑、尺寸及 SHA-256 在 data/manifests/images.jsonl。發布版不含第三方像素，下載後再核對。

查一題的簡單方式

```
import json
from pathlib import Path

sample_id = "VS/map/6/2/0"
path = Path("stage2/results/judgments.jsonl")
for line in path.read_text(encoding="utf-8").splitlines():
    row = json.loads(line)
    if row["sample_id"] == sample_id:
        print(row["question"])
        print(row["model_response_raw"])
        print(row["semantic_correctness"], row["final_binary_correctness"])
        print(row["short_explanation"])
```

歷史紀錄怎麼看？

judgments/batches 是初判，不可把它當成新版最終值；second_pass 是 397 題歷史複核；adjudication_decisions 是當時仲裁；consistency_v2 保存規範、全量重審、舊版快照及改動。正式數字統一以 results/judgments.jsonl 為準。

32 題 reference_dispute 表示參考或定義仍有疑義，不表示漏判。87 筆 explanation_issue_flag 是另記的文內說明問題，不可直接當成全部幻覺或錯誤解釋的總數。